

Relatório Descritivo e Exploratório dos Dados

Entrega 2 — Análise Exploratória e Estatística Descritiva

Programa de Pós-Graduação em Ciência da Computação — UFMA

Aluno(a): Pedro Assunção

Matrícula: _____

E-mail: assuncao.pedro@discente.ufma.br

Semestre: 2026.1

Data de entrega: 29/05/2026

Entrega 2 de 3

Título do Projeto: Extração de Indicadores Pedagógicos a partir de Resoluções Matemáticas: Processamento de Imagens e Análíticas de Aprendizagem para o Diagnóstico Educacional

Seção 0

Recapitulação da Entrega 1

0.1 Problema investigado

A correção tradicional binária baseada unicamente no resultado "certo ou errado" descarta informações pedagógicas cruciais, sendo incapaz de revelar dificuldades conceituais profundas ou identificar padrões latentes de falha[cite: 11, 12]. Na álgebra elementar, os erros cometidos pelos estudantes frequentemente derivam de misconceptions matemáticas — que consistem em erros conceituais recorrentes, padrões cognitivos de falha e a compreensão incorreta de regras algébricas estruturais. Este projeto investiga como diagnosticar automaticamente a natureza pedagógica dessas falhas a partir de imagens de resoluções, tratando o erro matemático como uma fonte primária de informação educacional.

0.2 Objetivo da análise

O objetivo desta análise é prioritariamente **descritivo e associativo**[cite: 18, 19]. Busca-se estruturar, mapear e validar as características físicas das imagens processadas e os metadados gerados pelo pipeline de reconhecimento, definindo como variáveis artificiais de deformação visual (ruído, desfoque, inclinação) associam-se à legibilidade e integridade da extração das sentenças, permitindo extrair e analisar indicadores de falha sob uma perspectiva puramente pedagógica de analítica de aprendizagem[cite: 11, 12].

0.3 Hipóteses iniciais

Hipótese Geral (H_1): “É possível extrair automaticamente indicadores pedagógicos relevantes a partir de resoluções de equações do primeiro grau utilizando técnicas de Processamento Digital de Imagens, OCR e regras matemáticas simbólicas.” [cite: 20]

0.4 Mudanças em relação à Entrega 1

A abordagem metodológica proposta inicialmente baseada no treinamento de Redes Neurais Convolucionais (CNN) *end-to-end* para classificação direta de imagens de equações foi completamente abandonada. Identificou-se que modelos estatísticos de caixa-preta baseados em matrizes brutas de pixels falham em representar com fidelidade a lógica gramatical intrínseca, a hierarquia de operadores e as regras simbólicas de transição matemática do problema. O escopo foi intencionalmente restringido ao domínio exclusivo de **Equações do Primeiro Grau**, eliminando variações de cálculo, integrais ou álgebra complexa em geral[cite: 21, 22]. O sistema foi blindado e simplificado para atuar com um Motor de Regras Matemáticas Simbólicas ali-

mentado por um OCR estruturado, eliminando o objetivo irreal de desenvolver um novo OCR comercial e concentrando os esforços no verdadeiro objetivo da pesquisa: a transformação de imagens matemáticas em indicadores pedagógicos analisáveis.

Seção 1

Fonte e Procedência dos Dados

1.1 Origem do dataset

O conjunto de dados é composto por um **dataset sintético gerado automaticamente** por meio de scripts customizados em Python[cite: 30, 31]. O uso acadêmico de dados sintéticos justifica-se por cinco pilares: (i) controle experimental absoluto sobre os fatores físicos aplicados; (ii) alta escalabilidade de instâncias para testes contínuos; (iii) ausência total de complicações éticas e restrições legais ligadas à LGPD; (iv) facilidade e exatidão matemática na rotulação automática de classes (*ground truth*); e (v) alta reprodutibilidade científica. O gerador cria passos de equações lineares aplicando automaticamente três categorias de interesse exaustivas e mutuamente exclusivas: `correto` (resolução correta), `erro_sinal` (troca de operadores $+$ e $-$ ou falha na mudança de termos) e `erro_fracao` (simplificação errada ou cancelamento inválido de frações).

1.2 Período coberto

Por se tratar de uma simulação controlada, os registros compreendem os ciclos contínuos de desenvolvimento, geração e estresse algorítmico computacional executados durante o semestre de 2026.1[cite: 32, 33].

1.3 Forma de coleta

Os dados são gerados e processados por um pipeline automatizado composto por quatro etapas[cite: 34, 35]:

- **Etapla 1 (Geração Sintética):** Criação automática de imagens contendo resoluções de equações do primeiro grau nas classes `correto`, `erro_sinal` e `erro_fracao`, com simulação de escrita manuscrita e aplicação de ruídos controlados (blur, rotação, sombras e variações de iluminação).
- **Etapla 2 (Pré-processamento com PDI):** Aplicação de binarização de Otsu, remoção de ruído, correção de inclinação (*deskew*) e operações morfológicas para melhorar a qualidade da imagem antes do OCR.
- **Etapla 3 (OCR e Reconhecimento):** Utilização do motor *Tesseract OCR* para converter os símbolos matemáticos presentes na imagem em uma representação textual.
- **Etapla 4 (Motor de Regras Simbólicas):** Análise da expressão extraída pelo OCR por meio de regras matemáticas implementadas em Python, permitindo a classificação da resolução em `correto`, `erro_sinal` ou `erro_fracao`.

1.4 Granularidade

Cada linha do dataset consolidado final representa **uma submissão de linha de resolução (passo algébrico da equação de primeiro grau) extraída e interpretada a partir de um arquivo de imagem**[cite: 36, 37].

1.5 Considerações éticas e de privacidade

O dataset é composto exclusivamente por matrizes geradas por algoritmos e strings sintéticas[cite: 38, 39]. Não há coleta de dados pessoais, imagens de cadernos de alunos reais ou informações sob custódia de sigilo institucional, operando em conformidade com os preceitos de transparência científica.

Reflexões iniciais:

- ▷ Os dados disponíveis são suficientes para responder à pergunta da Entrega 1?
- ▷ Há vieses conhecidos na coleta (ex.: amostra restrita a um curso, período atípico)?

Seção 2

Características Gerais dos Dados

Característica	Valor
Número de registros (linhas)	<i>A ser contabilizado com base no lote gerado (massa total de arquivos)</i>
Número de variáveis (colunas)	6 variáveis estruturadas
Variáveis numéricas	2 (ruído, rotacao)
Variáveis categóricas/nominais	3 (imagem, expressao, classe_erro)
Variáveis ordinais	1 (misconception)
Variáveis temporais	0
Registros com valores faltantes	<i>A ser determinado (casos de falha catastrófica de leitura de texto no OCR)</i>
Registros duplicados	0 (geração com sementes pseudoaleatórias exclusivas)

Como o projeto lida com arquivos matriciais originais ('.png') que passam pelo fluxo de transcrição, o dataset estruturado é uma tabela de metadados simulada qualitativamente abaixo conforme o planejamento de colunas do sistema[cite: 62]:

imagem	expressao	classe_erro	ruído	rotacao	misconception
line_001_c.png	"2x=12-6"	correto	1	-0.50	Nenhuma
line_002_es.png	"2x=5+3"	erro_sinal	3	2.15	Inversao_Operacao
line_003_ef.png	"(x+2)=2"	erro_fracao	2	-1.10	Falha_Estrutural
line_004_r.png	"	NaN	5	-4.80	Falha_Leitura_OCR

```
# Comandos úteis em pandas
df.shape
df.dtypes
df.head(5)
df.isnull().sum()
df.duplicated().sum()
```

Seção 3

Dicionário de Dados

Variável	Tipo	Domínio/Unidade	Descrição	% NA
imagem	Textual	Caminho do arquivo ('.png')	Identificador físico do arquivo de resolução matemática.	0%
expressao	Textual	String em formato ASCII	Texto e operadores extraídos diretamente da imagem pelo OCR.	<i>A ser medido</i>
classe_erro	Nominal	[correto, erro_sinal, erro_fracao]	Rótulo categórico atribuído pós-avaliação do motor de regras.	0%
ruído	Discreta	Inteiros de 0 a 5	Índice de intensidade de desfoque e sombra injetado.	0%
rotacao	Contínua	Graus decimais (-5.0° a +5.0°)	Ângulo rotacional aplicado artificialmente na imagem original.	0%

Variável	Tipo	Domínio/Unidade	Descrição	% NA
misconception	Nominal	[Nenhuma, Inversao_Op, Falha_Estrut]	Mapeamento pedagógico latente associado à natureza da falha.	0%

! Tipos possíveis: **nominal**, **ordinal**, **contínua**, **discreta**, **binária**, **temporal**, **textual**[cite: 75].

Reflexões iniciais:

- ▷ Os nomes das colunas são claros ou precisam ser renomeados?
- ▷ Há variáveis redundantes (ex.: idade e ano de nascimento)?
- ▷ Há variáveis que precisam ser derivadas a partir das originais para responder à pergunta de pesquisa?

Seção 4

Limpeza e Preparação dos Dados

4.1 Tratamento de Valores Faltantes

Variável	% NA	Estratégia	Justificativa
expressao	<i>A ser medido</i>	Remoção/Flag de exclusão operacional	Strings vazias ocorrem quando distorções visuais extremas impedem totalmente o OCR de extrair caracteres. Como as regras algébricas exigem sintaxe literal, o registro é descartado do cálculo de analítica.

4.2 Tratamento de Outliers

Variável	Método	Quant.	Decisão	Justificativa
rotacao	Filtro geométrico IQR	<i>A definir</i>	Remoção e descarte	Valores de inclinação fora dos limites operacionais controlados indicam falhas de simulação e devem ser eliminados.

4.3 Transformações e Codificações

- ▷ **Codificação de categóricas:** (*one-hot, label encoding, ordinal...*)

Aplicação posterior de *One-Hot Encoding* nas colunas categóricas nominais associadas aos tipos de operadores para viabilizar cálculos matriciais de associação estatística nas etapas finais do pipeline[cite: 99].

- ▷ **Normalização/escalamento:** (*min-max, z-score...*)

Conversão da variável contínua *rotacao* para escala de valor absoluto, facilitando o cruzamento unificado do impacto da magnitude da inclinação (independentemente do lado) sobre o sucesso do pipeline[cite: 100].

- ▷ **Variáveis derivadas:** (ex.: *criação de frequencia_semanal a partir de acessos e semana*)

A variável categórica *misconception* será derivada logicamente a partir do cruzamento exato entre a *classe_erro* e a topologia sintática mapeada pelo motor de regras matemáticas simbólicas[cite: 101].

▷ **Conversões de tipo:** (ex.: *string* → *datetime*)

Forçamento explícito das variáveis de controle físico *ruido* e *rotacao* para os tipos numéricos nativos (*int* e *float*) imediatamente após a unificação do arquivo de log do lote[cite: 102].

4.4 Resumo do Pré-processamento

Etapa	Antes	Depois
Total de registros	<i>N total de imagens geradas</i>	<i>N de imagens válidas pós-filtro OCR</i>
Total de variáveis	5 atributos nativos de simulação	6 atributos consolidados
Variáveis adicionadas	—	<i>misconception</i>
Variáveis removidas	—	—

Seção 5

Análise Descritiva Univariada

5.1 Variáveis Numéricas

Variável	Média	Med.	DP	Mín	Máx	Q1	Q3	Assim.
<i>rotacao</i>								<i>A ser preenchido via script após a execução do lote de processamento</i>
<i>ruido</i>								<i>A ser preenchido via script após a execução do lote de processamento</i>

```
import seaborn as sns
# Histogramas para checar distribuicao angular e intensidades de ruido
sns.histplot(df['rotacao'], kde=True)
sns.countplot(x='ruido', data=df)
```

Reflexões:

- ▷ A distribuição é simétrica, assimétrica à direita ou à esquerda?
- ▷ Existem outliers? Eles parecem erros ou casos atípicos relevantes?
- ▷ Há variáveis com pouca variação (DP baixo) que talvez não contribuam para análises posteriores?
- ▷ Os valores estão dentro do domínio esperado?

5.2 Variáveis Categóricas

Variável	Categoria	Freq. absoluta	Freq. relativa (%)
<i>classe_erro</i>	<i>correto</i>	<i>A preencher</i>	<i>A ser calculado</i>
	<i>erro_sinal</i>	<i>A preencher</i>	<i>A ser calculado</i>
	<i>erro_fracao</i>	<i>A preencher</i>	<i>A ser calculado</i>
<i>misconception</i>	<i>Inversao_Op</i>	<i>A preencher</i>	<i>A ser calculado</i>
	<i>Falha_Estrut</i>	<i>A preencher</i>	<i>A ser calculado</i>

```
df['classe_erro'].value_counts(normalize=True) * 100
sns.countplot(x='classe_erro', data=df)
```

Reflexões:

- ▷ Há desbalanceamento entre as categorias? (ex.: 95% in one class)
- ▷ Esse desbalanceamento pode comprometer comparações ou modelagens futuras?
- ▷ Categorias raras devem ser agrupadas em “Outros”?

Seção 6**Análise Descritiva Bivariada e Exploratória****6.1 Cruzamentos Relevantes**

Variável A	Variável B	Justificativa do cruzamento
rotacao (Numérica)	classe_erro (Categórica)	Avaliar o impacto da inclinação da imagem na capacidade do sistema de identificar corretamente os tipos de erro matemático.
ruido (Discreta)	classe_erro (Categórica)	Verificar como diferentes níveis de degradação visual influenciam a classificação final produzida pelo pipeline.
classe_erro (Categórica)	misconception (Categórica)	Mapear a associação entre os erros detectados e as categorias pedagógicas utilizadas para diagnóstico educacional.
classe_erro (Categórica)	Frequência de Ocorrência	Identificar quais padrões de erro aparecem com maior recorrência no conjunto de dados gerado.
misconception (Categórica)	Frequência de Ocorrência	Investigar quais dificuldades conceituais tendem a ser mais representativas no cenário experimental analisado.

6.2 Numérica × Numérica — Correlações

Par de variáveis	Coef.	Tipo	Interpretação
rotacao × ruido	<i>A calcular</i>	Spearman	Espera-se correlação nula, comprovando a independência dos eixos gerados.

```
df.corr(method='spearman')
sns.heatmap(df.corr(), annot=True, cmap='coolwarm')
```

6.3 Categórica × Numérica

O script executará a plotagem de boxplots agrupando a magnitude absoluta da `rotacao` para cada nível de `classe_erro`, expondo se os erros cognitivos extraídos mantêm estabilidade geométrica ou sofrem interferência de distorção angular da imagem[cite: 155, 156].

6.4 Categórica × Categórica

Mapeamento de tabelas de contingência cruzando a `classe_erro` com as categorias de `misconception` para extração dos indicadores de distribuição de frequências que alimentarão as ferramentas visuais de análise pedagógica[cite: 158, 159].

Reflexões para análise futura:

- ▷ Quais relações se mostram mais fortes nos dados?
- ▷ Há associações inesperadas que merecem investigação?
- ▷ Correlação observada implica causalidade? Que variáveis de confundimento podem estar agindo?

Seção 7

Insights Preliminares

Insight 1

As técnicas de Processamento Digital de Imagens (PDI) clássicas atuam como um redutor crítico de dimensionalidade e ruído essencial no pipeline. Sem a binarização morfológica de Otsu e o isolamento de canais via OpenCV, artefatos visuais de background (como as pautas azuis simuladas do papel de caderno) injetam ruídos aleatórios de caracteres na string gerada pelo Tesseract OCR, provocando falsas violações algébricas e corrompendo a integridade analítica das métricas de erro.

Insight 2

Sobre reconhecimento e classificação, espera-se que o motor de regras seja capaz de distinguir corretamente as categorias `erro_sinal` e `erro_fracao`, produzindo classificações compatíveis com os rótulos originalmente inseridos durante a geração sintética. Entretanto, limitações do OCR na leitura de símbolos matemáticos podem ocasionar erros de interpretação, especialmente em expressões contendo frações ou caracteres visualmente semelhantes.

Insight 3

Sob a ótica de Learning Analytics, espera-se que a distribuição das classes `erro_sinal` e `erro_fracao` permita a identificação de padrões distintos de dificuldades matemáticas. Mesmo em um ambiente sintético controlado, a frequência relativa dessas categorias pode indicar quais tipos de transformação algébrica tendem a gerar mais falhas durante o processo de resolução, demonstrando o potencial do sistema para produzir indicadores pedagógicos automaticamente a partir de expressões matemáticas processadas[cite: 11, 12].

Seção 8

Hipóteses Reformuladas

Hipótese inicial (Entrega 1)	Status	Hipótese reformulada (para Entrega 3)
É possível extrair indicadores pedagógicos a partir de imagens de resoluções utilizando técnicas automáticas de PDI e OCR.	Refinada	É possível extrair e categorizar automaticamente indicadores pedagógicos de <i>misconceptions</i> em equações do primeiro grau (<code>erro_sinal</code> e <code>erro_fracao</code>) a partir de imagens processadas por PDI clássico e OCR Tesseract, utilizando validação simbólica determinística baseada na coerência de passos.

Seção 9

Limitações dos Dados e Próximos Passos

9.1 Limitações Identificadas

A principal limitação reside na rigidez sintática do Motor de Regras Matemáticas Simbólicas, estruturado estritamente para a gramática delimitada de equações lineares simples de primeiro grau. O sistema não é capaz de interpretar anotações informais humanas adjacentes, tais como setas indicativas de mudança de termo, rasuras físicas riscadas sobre o papel ou comentários textuais marginais[cite: 185, 187, 188]. Além disso, o motor Tesseract OCR exibe vulnerabilidade intrínseca no escaneamento estritamente linear de layouts com divisão espacial vertical (frações), gerando instabilidades estruturais na string que demandam correção morfológica severa e prévia no nível de PDI.

9.2 Planejamento para a Entrega 3

▷ Técnica analítica a ser aplicada:

Mineração de dados educacionais baseada em matrizes de correspondência diagnóstica e avaliação estrita de modelos de classificação categórica[cite: 190].

▷ Variável-alvo (se houver):

A variável categórica nominal de diagnóstico estrutural: `classe_erro` (comportando os alvos: `correto`, `erro_sinal`, `erro_fracao`)[cite: 195].

▷ Pré-processamentos adicionais previstos:

Filtragem sintática de strings textuais cruas e tokenização automatizada de operadores aritméticos para alimentação lógica do interpretador algébrico em Python[cite: 196].

▷ **Métricas de avaliação previstas:**

O pipeline será validado computacionalmente por meio do confronto estrito dos rótulos extraídos contra o *ground truth* conhecido do gerador sintético, calculando métricas de **Acurácia, Precisão, Recall e F1-Score**, consolidadas em **Matrizes de Confusão**[cite: 197].

Seção R

Referências

ROMERO, C.; VENTURA, S. Educational data mining: a review of the state of the art. **IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)**, v. 37, n. 6, p. 135-146, 2007.

SMITH, R. An overview of the Tesseract OCR engine. In: **Proceedings of the Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)**. IEEE, 2007. v. 2, p. 629-633.

BAKER, Ryan S. Data mining for education. **International Encyclopedia of Education**, v. 7, p. 112-118, 2010.

✓ Checklist de Submissão

- ☐ Identificação preenchida (nome, matrícula, e-mail) [cite: 203]
- ☐ Recapitulação da Entrega 1 incluída [cite: 203]
- ☐ Fonte e procedência dos dados documentadas [cite: 205]
- ☐ Dicionário de dados completo (todas as variáveis) [cite: 205]
- ☐ Decisões de limpeza e preparação justificadas [cite: 205]
- ☐ Análise univariada para variáveis numéricas e categóricas [cite: 206]
- ☐ Pelo menos uma análise bivariada relevante para a pergunta de pesquisa [cite: 208]
- ☐ Visualizações com títulos, legendas e eixos rotulados [cite: 208]
- ☐ Insights preliminares amarrados às evidências [cite: 209]
- ☐ Hipóteses reformuladas [cite: 210]
- ☐ **Notebook (.ipynb) ou script reprodutível submetido junto ao relatório** [cite: 211]
- ☐ Referências listadas [cite: 211]